Report on Homework 3

——Machine Learning

刘滨瑞

2021012579　未央-水木 12

2023 年 12 月 20 日

2　决策树与随机森林

2.1　ID3 算法无法找到最优解的一个情形

1. 证明：使用 ID3 算法得到的决策树至少有 $\frac{1}{4}$ 的训练误差。

   第一次分割：

   若按 1 号特征分割，信息增益为：

   $$IG = (-\frac{2}{4}\log_2\frac{2}{4} - \frac{2}{4}\log_2\frac{2}{4}) - \frac{3}{4}(-\frac{2}{3}\log_2\frac{2}{3} - \frac{1}{3}\log_2\frac{1}{3}) - 0 = 0.311$$

   若按 2 号特征或 3 号特征分割，信息增益为：

   $$IG = (-\frac{2}{4}\log_2\frac{2}{4} - \frac{2}{4}\log_2\frac{2}{4}) - 2\times\frac{2}{4}(-\frac{1}{2}\log_2\frac{1}{2} - \frac{1}{2}\log_2\frac{1}{2}) = 0$$

   因此，在 ID3 算法中，第一次分割应基于 1 号特征。此时，决策树形状如图 1 所示。右侧子集合已完成分类，在第二次分割时，我们只需要关注左侧子集合。

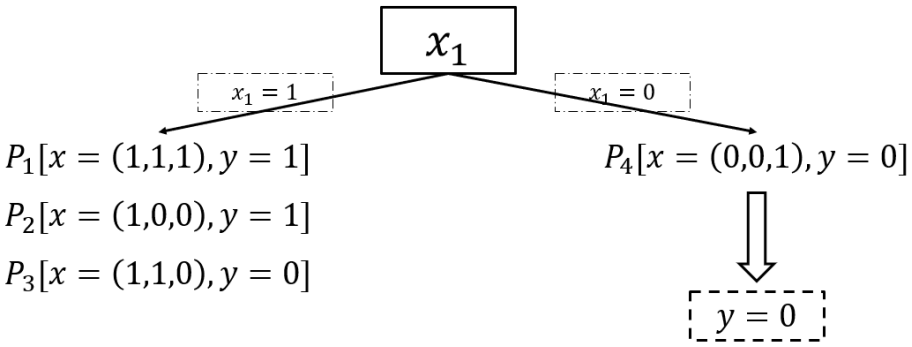

图 1: 第一次分割后的决策树形状

第二次分割：

无论按照 2 号特征还是 3 号特征，信息增益均为：

$$IG = (-\frac{2}{3}\log_2\frac{2}{3} - \frac{1}{3}\log_2\frac{1}{3}) - \frac{2}{3}(-\frac{1}{2}\log_2\frac{1}{2} - \frac{1}{2}\log_2\frac{1}{2}) - 0 = 0.252$$

因此，在 ID3 算法中，第二次分割等可能地基于 2 号特征或 3 号特征。此时，可能的决策树形状如图 2 所示。

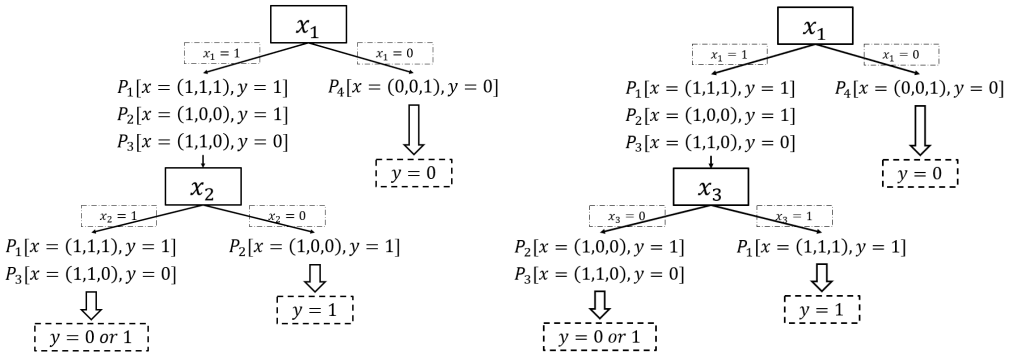

(a) 基于 2 号特征进行分割　　(b) 基于 3 号特征进行分割

图 2: 第二次分割后的决策树形状

可以看出，在两种深度为 2 的决策树中，均存在一个叶节点含有两种类别的样本，因此至少有一个样本会被错误分类。这即说明了基于 ID3 算法得到的决策树至少会有 $\frac{1}{4}$ 的训练误差。

2. 构造一棵深度为 2，且训练误差为 0 的决策树。

图 3 所示的决策树满足题目要求。

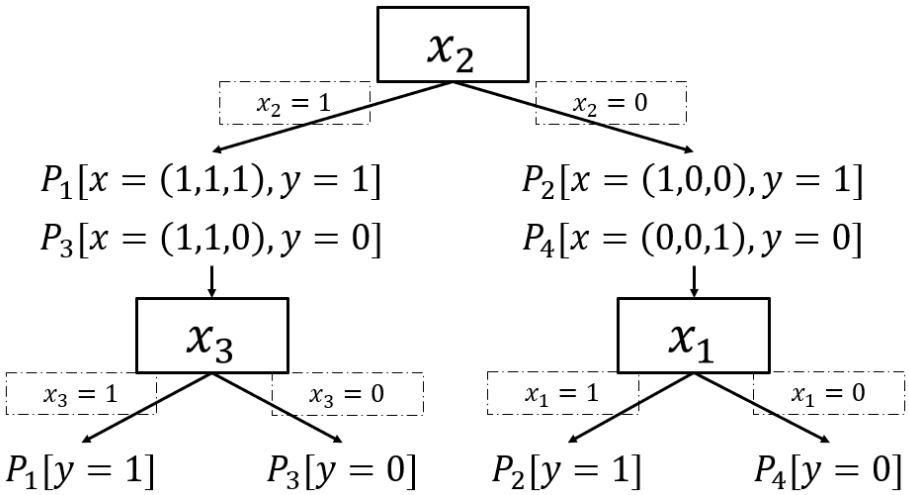

图 3: 深度为 2，训练误差为 0 的决策树

2.2 随机森林

1. 求任意一个特定的特征从未被选中分割的概率。

   考虑到随机森林中的每棵二叉决策树都有 h 个内部节点，而每个节点都会从本树未使用过的特征中随机选取 $K = 1$ 个用于分类决策。因此，选取特征的过程等价于：每棵决策树随机地从 d 个特征中选取 h 个。故对于某一特定的特征，任意一棵决策树中未使用此特征的概率为：$1 - \frac{h}{d}$。

   由于每个决策树选取特征的过程相互独立，在总共 t 棵决策树中，任意一个特定的特征从未被选中分割的概率为：

$$\mathbb{P} = (1 - \frac{h}{d})^t$$

2. 求任意一个特定的样本从未在任何一棵树中被考虑的概率。

每棵决策树会使用 m 个自主采样得到的样本，总样本规模为 n。对于某一特定的样本，在任意一棵决策树中未考虑过该样本的概率为：$(1-\frac{1}{n})^m$。

同样地，由于每个决策树采样的过程相互独立，在总共 t 棵决策树中，任意一个特定的样本从未在任何一棵树中被考虑的概率为：

$$\mathbb{P} = (1-\frac{1}{n})^{mt}$$

2.3 代码实验

决策树的实现代码已经按要求补全，详见./code/tree.py 中的相应部分。

决策树在二分类问题和回归问题上的结果如图 4、图 5 所示。

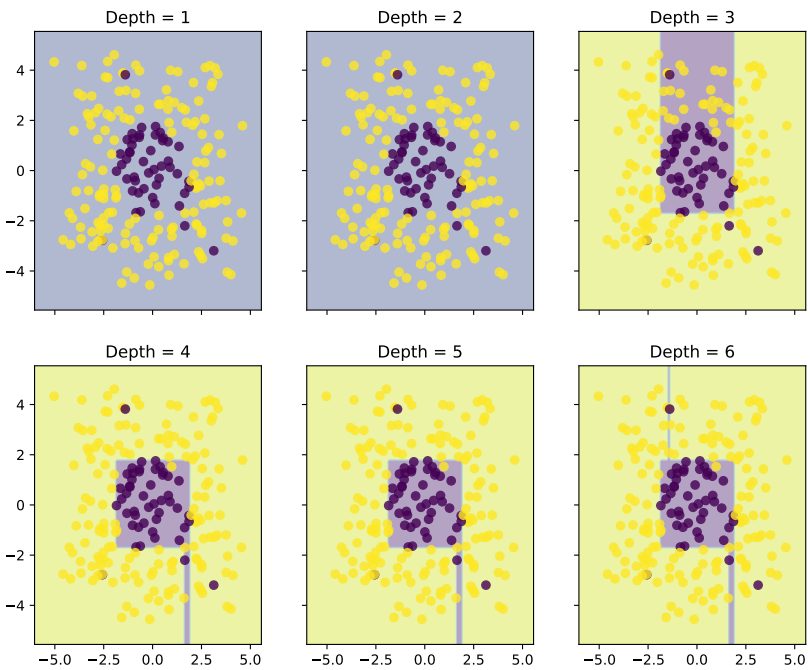

图 4: 决策树在二分类问题上的结果

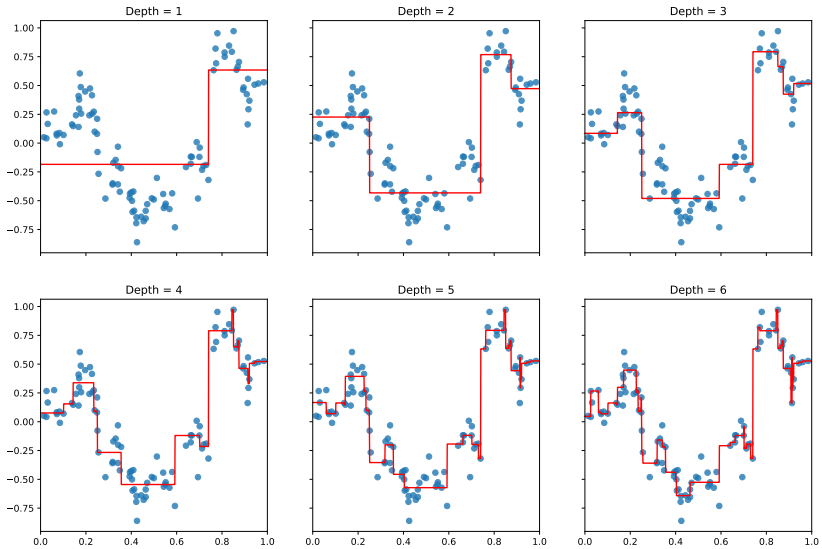

图 5: 决策树在回归问题上的结果

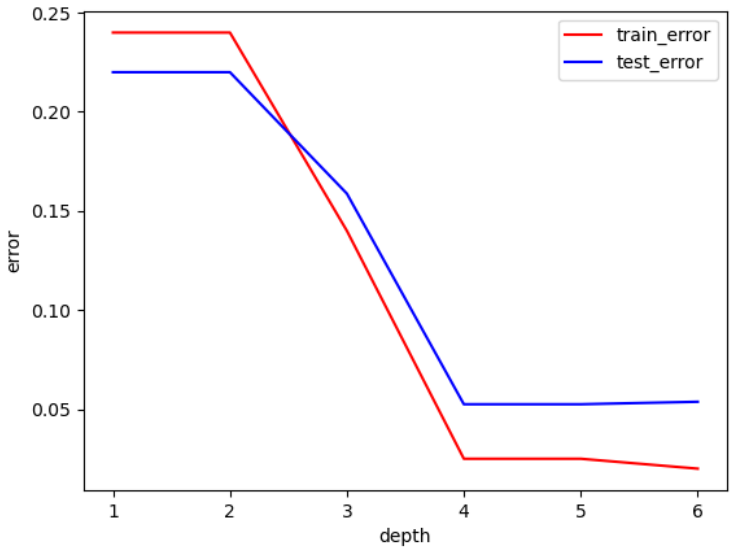

图 6: 在二分类问题上，不同深度的决策树的训练误差与测试误差

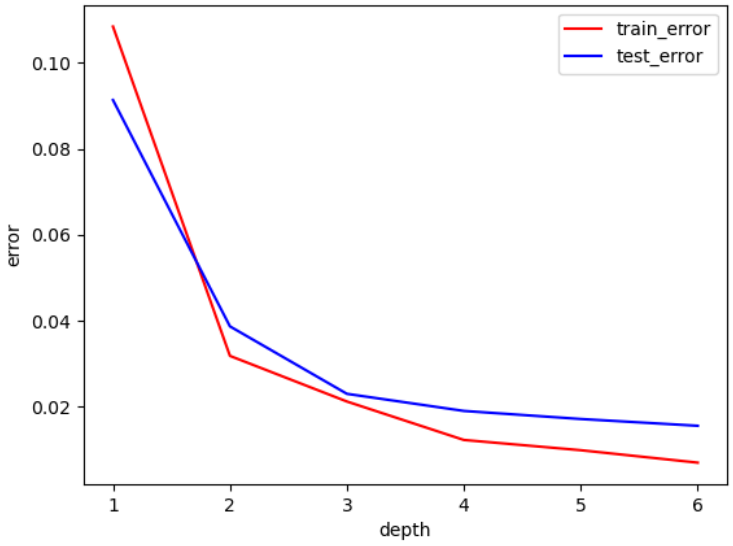

图 7: 在回归问题上，不同深度的决策树的训练误差与测试误差

另外，在两类问题中，我们还统计了不同深度的决策树的训练误差和测试误差。将结果绘制成图像，如图 6、图 7 所示。

可以看出，决策树在训练集中的误差随着深度的提高而迅速下降，拟合数据的能力明显提高。这是因为决策树的深度越大，其就拥有更多可用于分类判断的子节点，从而使得模型具有更高的复杂度与拟合能力，可以捕捉到更多数据中的特征。

在二分类问题中，当决策树深度大于 4 后，模型在测试集上的误差已经不再继续降低，体现出的分类效果也已经十分良好，这说明取决策树深度等于 4 是较为合适的，模型在该深度下可以充分拟合数据。此时如果继续提高决策树的深度，可能会出现过拟合的问题。

而在回归问题中，直到深度等于 6 时，模型在测试集上的误差仍保持着继续降低的趋势，此时可以进一步提高决策树的深度，以更好地拟合数据。

3 提升算法

3.1 噪声不敏感的 AdaBoost 算法

1. 证明 G 是 $\mathbb{R}$ 上的凸函数且处处可导。

   显然，在 $(-\infty, 0]$ 和 $[0, \infty)$ 上，G 均为可导的凸函数。我们只需要证明 G 在 0 处的左右导数相等，并证明对于任意的 $x_1 \leq 0, x_2 > 0$ 和 $\lambda \in (0,1)$，有 $\lambda G(x_1) + (1-\lambda)G(x_2) \geq G(\lambda x_1 + (1-\lambda)x_2)$ 成立即可。

   对于第一个子命题，有：

$$
\begin{aligned}
G'(x)|_{x=0^-} =& (e^x)|_{x=0^-} = 1 \\
G'(x)|_{x=0^+} =& (1)|_{x=0^+} = 1
\end{aligned}
$$

   二者相等，子命题成立。

   对于第二个子命题，若 $x_0 = \lambda x_1 + (1-\lambda)x_2 > 0$，则：

$$
\begin{aligned}
\lambda G(x_1) + (1-\lambda)G(x_2) =& \lambda e^{x_1} + (1-\lambda)(x_2+1) \\
\geq& \lambda(x_1+1) + (1-\lambda)(x_2+1) \\
=& (\lambda x_1 + (1-\lambda)x_2) + 1 = G(x_0)
\end{aligned}
$$

   若 $x_0 \leq 0$，此时有 $\lambda \geq \frac{x_0}{x_1}$。我们构造函数 $u(x) = \frac{e^x - 1}{x}, x \leq 0$。使用常用不等式 $e^x \leq \frac{1}{1-x}$：

$$
u'(x) = \frac{xe^x - e^x + 1}{x^2} \geq \frac{(x-1)(\frac{1}{1-x}) + 1}{x^2} = 0
$$

   这说明 $u(x)$ 是递增函数，于是：

$$
\begin{aligned}
\lambda G(x_1) + (1-\lambda)G(x_2) - G(x_0) =& \lambda e^{x_1} + (1-\lambda)(\frac{x_0 - \lambda x_1}{1-\lambda} + 1) - e^{x_0} \\
=& \lambda e^{x_1} + x_0 - \lambda x_1 + 1 - \lambda - e^{x_0} \\
=& \lambda(e^{x_1} - x_1 - 1) - (e^{x_0} - x_0 - 1) \\
\geq& x_0(\frac{e^{x_1} - x_1 - 1}{x_1} - \frac{e^{x_0} - x_0 - 1}{x_0})
\end{aligned}
$$

$$= - x_0(u(x_0) - u(x_1)) \geq 0$$

即：$\lambda G(x_1) + (1-\lambda)G(x_2) \geq G(x_0)$，子命题成立。

综上，我们证明了 G 是 $\mathbb{R}$ 上处处可导的凸函数。

2. 给出第 t 步时弱分类器 h_t 应当优化的损失函数 ϵ_t 的表达式。

在第 t 步时，待优化的损失函数 ϵ_t 可表示为：

$$\epsilon_t = \sum_{i=1}^{m} \overline{D}_t(i) \mathbb{I}_{[y_i \neq h_t(\boldsymbol{x}_i)]}$$

下面，我们给出 $\overline{D}_t(i)$ 的表达式。

设 $\mathcal{H} = \{h_1, h_2, ..., h_N\}$，第 t 步时，若在方向 k 上执行坐标下降，有：

$$\begin{aligned}
&F'(\overline{\boldsymbol{\alpha}}_{t-1}, \boldsymbol{e}_k) \\
=&\lim_{\eta \to 0} \frac{F(\overline{\boldsymbol{\alpha}}_{t-1} + \eta \boldsymbol{e}_k) - F(\overline{\boldsymbol{\alpha}}_{t-1})}{\eta} \\
=&\lim_{\eta \to 0} \frac{1}{\eta}(\frac{1}{m} \sum_{i=1}^{m} (G(-y_i \overline{\boldsymbol{\alpha}}_{t-1}^T \boldsymbol{h}(\boldsymbol{x}_i) - \eta y_i h_k(\boldsymbol{x}_i)) - G(-y_i \overline{\boldsymbol{\alpha}}_{t-1}^T \boldsymbol{h}(\boldsymbol{x}_i)))) \\
=&-\frac{1}{m} \sum_{i=1}^{m} y_i h_k(\boldsymbol{x}_i) G'(-y_i \sum_{j=1}^{N} \overline{\alpha}_{t-1,j} h_j(\boldsymbol{x}_i))
\end{aligned}$$

按 AdaBoost 算法的定义，此时应满足：

$$\overline{D}_t(i) \overline{Z}_t = G'(-y_i \sum_{j=1}^{N} \overline{\alpha}_{t-1,j} h_j(\boldsymbol{x}_i))$$

其中 $\overline{Z}_t$ 为归一化因子，G' 由 3.1.1 中求得的导数定义。

综上，我们有：

$$\begin{aligned}
\overline{Z}_t =& \sum_{i=1}^{m} G'(-y_i \sum_{j=1}^{N} \overline{\alpha}_{t-1,j} h_j(\boldsymbol{x}_i)) \\
\overline{D}_t(i) =& \frac{G'(-y_i \sum_{j=1}^{N} \overline{\alpha}_{t-1,j} h_j(\boldsymbol{x}_i))}{\overline{Z}_t}
\end{aligned}$$

3.2 探究 AdaBoost 算法是否能使用完全相同的弱分类器

1. 证明：$\sum_{i=1}^{m} D_{t+1}(i)\mathbb{I}_{[y_i \neq h_t(\boldsymbol{x}_i)]} = \frac{1}{2}$。

   首先，注意到：

$$\sum_{i=1}^{m} D_{t+1}(i)\mathbb{I}_{[y_i \neq h_t(\boldsymbol{x}_i)]} + \sum_{i=1}^{m} D_{t+1}(i)\mathbb{I}_{[y_i = h_t(\boldsymbol{x}_i)]} = \sum_{i=1}^{m} D_{t+1}(i) = 1$$

   因此，只需要证明：

$$\sum_{i=1}^{m} D_{t+1}(i)\mathbb{I}_{[y_i \neq h_t(\boldsymbol{x}_i)]} = \sum_{i=1}^{m} D_{t+1}(i)\mathbb{I}_{[y_i = h_t(\boldsymbol{x}_i)]}$$

   我们有：

$$\begin{aligned}
&\sum_{i=1}^{m} D_{t+1}(i)\mathbb{I}_{[y_i \neq h_t(\boldsymbol{x}_i)]} - \sum_{i=1}^{m} D_{t+1}(i)\mathbb{I}_{[y_i = h_t(\boldsymbol{x}_i)]} \\
=&\frac{1}{Z_t}\Big(\sum_{i=1}^{m} e^{-\alpha_t y_i h_t(\boldsymbol{x}_i)} D_t(i)\mathbb{I}_{[y_i \neq h_t(\boldsymbol{x}_i)]} - \sum_{i=1}^{m} e^{-\alpha_t y_i h_t(\boldsymbol{x}_i)} D_t(i)\mathbb{I}_{[y_i = h_t(\boldsymbol{x}_i)]}\Big) \\
=&\frac{1}{Z_t}\Big(\sum_{i, y_i \neq h_t(\boldsymbol{x}_i)} e^{\alpha_t} D_t(i) - \sum_{i, y_i = h_t(\boldsymbol{x}_i)} e^{-\alpha_t} D_t(i)\Big) \\
=&\frac{1}{Z_t}\Big(\sum_{i, y_i \neq h_t(\boldsymbol{x}_i)} e^{\frac{1}{2}\log\frac{1-\epsilon_t}{\epsilon_t}} D_t(i) - \sum_{i, y_i = h_t(\boldsymbol{x}_i)} e^{-\frac{1}{2}\log\frac{1-\epsilon_t}{\epsilon_t}} D_t(i)\Big) \\
=&\frac{1}{Z_t}\Big(\sqrt{\frac{1-\epsilon_t}{\epsilon_t}} \sum_{i, y_i \neq h_t(\boldsymbol{x}_i)} D_t(i) - \sqrt{\frac{\epsilon_t}{1-\epsilon_t}} \sum_{i, y_i = h_t(\boldsymbol{x}_i)} D_t(i)\Big) \\
=&\frac{1}{Z_t}\Big(\sqrt{\frac{1-\epsilon_t}{\epsilon_t}}(\epsilon_t) - \sqrt{\frac{\epsilon_t}{1-\epsilon_t}}(1-\epsilon_t)\Big) \\
=&0
\end{aligned}$$

   命题得证。

2. 说明第 $t+1$ 步选取的弱分类器 h_{t+1} 不会与 h_t 相同。

   若第 $t+1$ 步选取的弱分类器 $h_{t+1} = h_t$，则：

$$\epsilon_{t+1} = \sum_{i=1}^{m} D_{t+1}\mathbb{I}_{[y_i \neq h_{t+1}(\boldsymbol{x}_i)]} = \sum_{i=1}^{m} D_{t+1}\mathbb{I}_{[y_i \neq h_t(\boldsymbol{x}_i)]} = \frac{1}{2}$$

但是，在 AdaBoost 算法中，我们选取的 h_{t+1} 是在 $t+1$ 轮迭代中具有最小经验误差的合法弱分类器，必然有 $\epsilon_{t+1} < \frac{1}{2}$ 成立，矛盾！

因此，第 $t+1$ 步选取的弱分类器 h_{t+1} 不会与 h_t 相同。

3.3 AdaBoost 的训练误差

1. 证明：当 $T > \frac{\log m}{2\gamma^2}$ 时，AdaBoost 的训练误差可以达到 0。

   根据课件上的结论，AdaBoost 算法的训练误差存在一个上界：

$$\hat{\mathcal{E}}(h) \leq \exp(-2\gamma^2 T) < \exp(-2\gamma^2 \frac{\log m}{2\gamma^2}) = \frac{1}{m}$$

   另一方面，若 $\hat{\mathcal{E}}(h) > 0$，则意味着至少有一个样本被错误分类。根据 $\hat{\mathcal{E}}(h)$ 的定义：

$$\hat{\mathcal{E}}(h) = \frac{1}{m}\sum_{i=1}^{m} \mathbb{I}_{[y_i f(\boldsymbol{x}_i) \leq 0]} \geq \frac{1}{m}$$

   矛盾！因此，当 $T > \frac{\log m}{2\gamma^2}$ 时，有 $\hat{\mathcal{E}}(h) = 0$ 成立。

3.4 简化版本的 AdaBoost

1. 试找出一个合理的固定 α 取值，使得最终得到的分类器的训练误差不多于 $(1-4\gamma^2)^{\frac{T}{2}}$。

   取 $\alpha = \frac{1}{2}\log\frac{1+2\gamma}{1-2\gamma}$，下面我们证明 AdaBoost 算法训练得到的分类器的训练误差不多于 $(1-4\gamma^2)^{\frac{T}{2}}$。

   根据训练误差的定义：

$$\begin{aligned}\hat{\mathcal{E}}(h) = \frac{1}{m}\sum_{i=1}^{m} \mathbb{I}_{[y_i f(\boldsymbol{x}_i) \leq 0]} \leq & \frac{1}{m}\sum_{i=1}^{m} e^{-y_i f(\boldsymbol{x}_i)} \\ \leq & \frac{1}{m}\sum_{i=1}^{m} (m\prod_{t=1}^{T} Z_t) D_{T+1}(i)\end{aligned}$$

$$
\begin{aligned}
&= \prod_{t=1}^{T} Z_t
\end{aligned}
$$

而对于每个 Z_t，有：

$$
\begin{aligned}
Z_t = \sum_{i=1}^{m} D_t(i) e^{-\alpha y_i h_t(\boldsymbol{x}_i)} &= \sum_{i, y_i \neq h_t(\boldsymbol{x}_i)} e^{\alpha} D_t(i) + \sum_{i, y_i = h_t(\boldsymbol{x}_i)} e^{-\alpha} D_t(i) \\
&= \epsilon_t e^{\alpha} + (1 - \epsilon_t) e^{-\alpha} \\
&= \epsilon_t \sqrt{\frac{1+2\gamma}{1-2\gamma}} + (1 - \epsilon_t) \sqrt{\frac{1-2\gamma}{1+2\gamma}} \\
&\leq \frac{1-2\gamma}{2} \sqrt{\frac{1+2\gamma}{1-2\gamma}} + \frac{1+2\gamma}{2} \sqrt{\frac{1-2\gamma}{1+2\gamma}} \\
&= \frac{1}{2} \sqrt{1-4\gamma^2} + \frac{1}{2} \sqrt{1-4\gamma^2} \\
&= \sqrt{1-4\gamma^2}
\end{aligned}
$$

综上，

$$
\hat{\mathcal{E}}(h) = \prod_{t=1}^{T} Z_t \leq (\sqrt{1-4\gamma^2})^T = (1-4\gamma^2)^{\frac{T}{2}}
$$

3.5 Gradient Boosting Machines

1. 算法流程补全。

   (b) $h_t = \arg\min_{h \in \mathcal{F}} \sum_{i=1}^{n} (h(\boldsymbol{x}_i) + \boldsymbol{g}_{t,i})^2$

   (d) $f_t(\boldsymbol{x}) = f_{t-1}(\boldsymbol{x}) + \alpha_t h_t(\boldsymbol{x})$

2. 回归问题中的 $\boldsymbol{g}_t$ 与 h_t。

   将损失函数的形式代入 3.5.1 中，得：

$$
\begin{aligned}
\boldsymbol{g}_t &= (\hat{\boldsymbol{y}}_i - \boldsymbol{y}_i)_{i=1}^{n} = (f_{t-1}(\boldsymbol{x}_i) - \boldsymbol{y}_i)_{i=1}^{n} \\
h_t &= \arg\min_{h \in \mathcal{F}} \sum_{i=1}^{n} (h(\boldsymbol{x}_i) + f_{t-1}(\boldsymbol{x}_i) - \boldsymbol{y}_i)^2
\end{aligned}
$$

3. 二分类问题中的 $\boldsymbol{g}_t$ 与 h_t。

将损失函数的形式代入 3.5.1 中，得：

$$\boldsymbol{g}_t = (\frac{-\boldsymbol{y}_i}{1+e^{\boldsymbol{y}_i\hat{\boldsymbol{y}}_i}})_{i=1}^n = (\frac{-\boldsymbol{y}_i}{1+e^{\boldsymbol{y}_i f_{t-1}(\boldsymbol{x}_i)}})_{i=1}^n$$

$$h_t = \arg\min_{h\in\mathcal{F}} \sum_{i=1}^n (h(\boldsymbol{x}_i) - \frac{\boldsymbol{y}_i}{1+e^{\boldsymbol{y}_i f_{t-1}(\boldsymbol{x}_i)}})^2$$

4. 代码实验。

GBM 的实现代码已经按要求补全，详见./code/boosting.py 中的相应部分。

使用 L2 loss 的 GBM 在二分类问题和回归问题上的结果如图 8、图 10 所示。

使用 logistics loss 的 GBM 在二分类问题上的结果如图 9 所示。

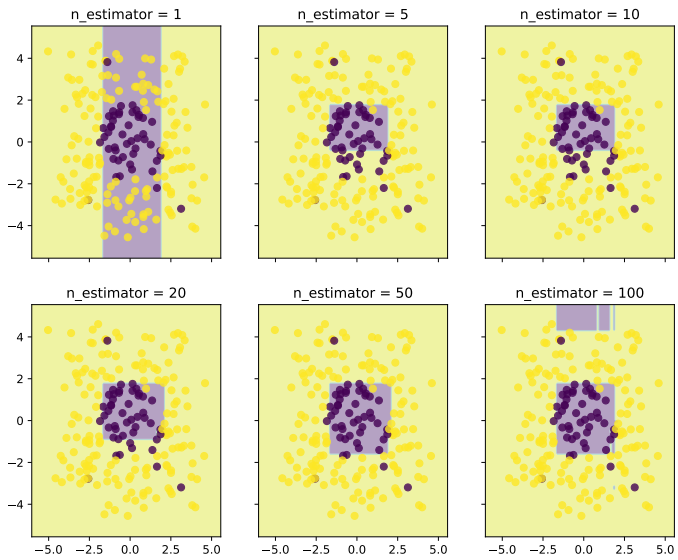

图 8: 使用 L2 loss 的 GBM 在二分类问题上的结果

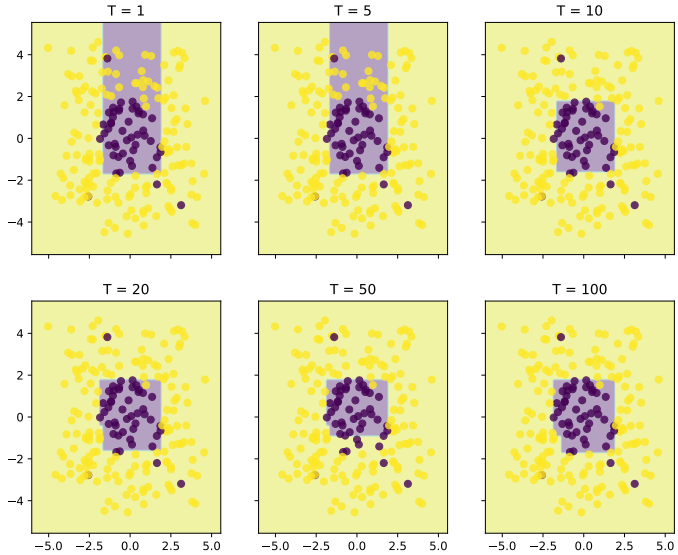

图 9: 使用 logistics loss 的 GBM 在二分类问题上的结果

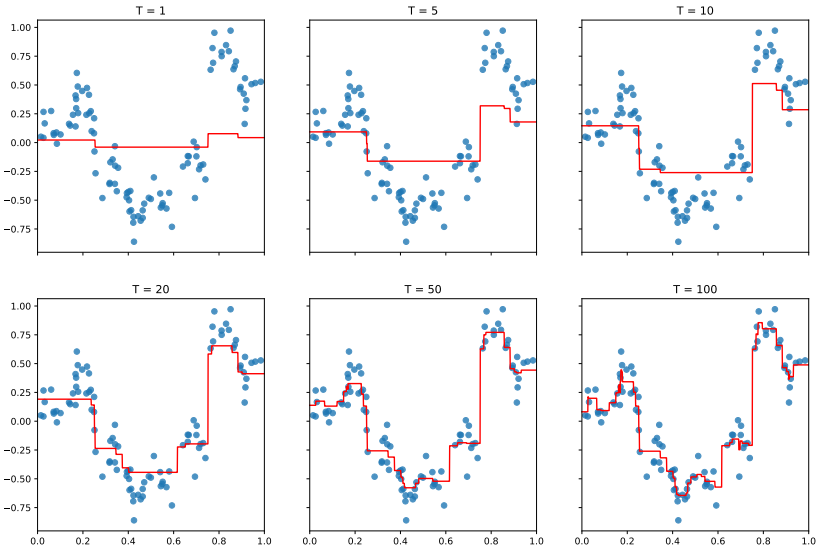

图 10: 使用 L2 loss 的 GBM 在回归问题上的结果

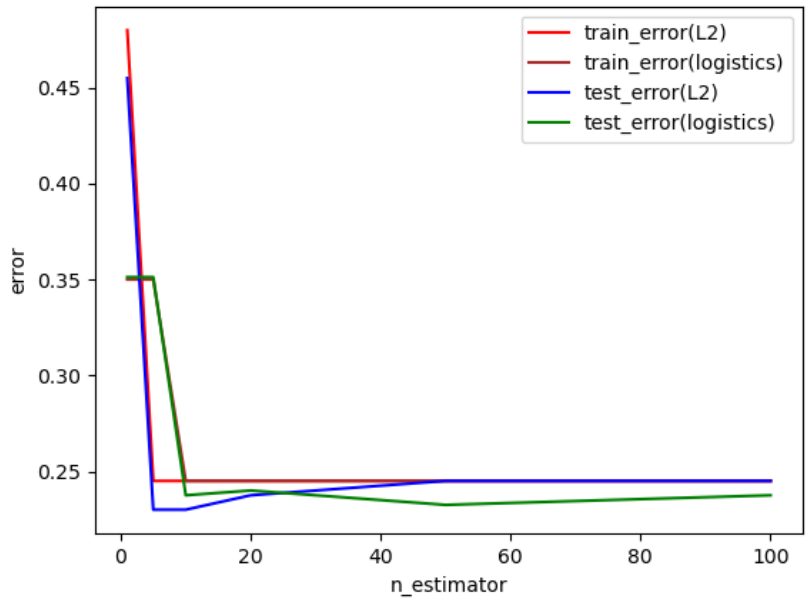

图 11: 在二分类问题上，不同基学习器数目 GBM 的训练误差与测试误差

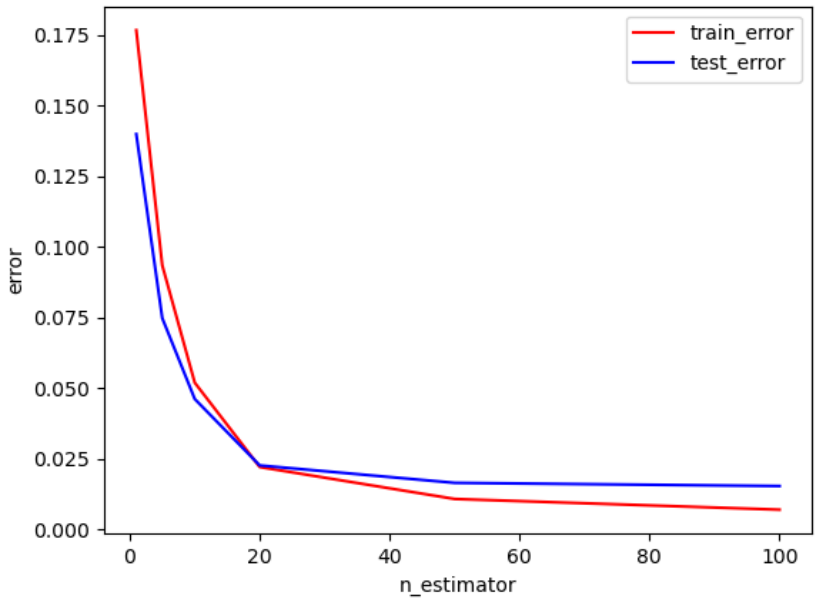

图 12: 在回归问题上，不同基学习器数目 GBM 的训练误差与测试误差

另外，在两类问题中，我们还统计了不同基学习器数目情况下模型的训练误差和测试误差。将结果绘制成图像，如图 11、图 12 所示。

可以看出，在二分类问题中，不论使用哪一种损失函数，GBM 在训练集上的误差都随着基学习器数目的增加而极快地降低，在 $n_{estimator} > 10$ 时，GBM 在训练集上的误差已完全收敛，在结果中也表现出了优秀的分类效果。这印证了课堂上我们基于学习理论得出的结论：GBM 有着非常强的拟合能力。

而当 $n_{estimator}$ 在 10 左右时，GBM 在验证集上的误差已达到最小值，此后若继续提高 $n_{estimator}$，在验证集上的误差反而增大。这说明在 $n_{estimator} > 10$ 时，模型出现了过拟合问题。

横向对比 L2 损失函数与 logistics 损失函数，两种 GBM 在训练集与测试集上的最小损失相近，但基于 logistics 损失函数的 GBM 收敛更慢，推测可能的原因是：logistics 损失函数的梯度信号更弱。

而在回归问题中，随着基学习器数目的增多，模型在训练集和测试集上的误差仍保持着继续降低的趋势，说明即使在 $n_{estimator} = 100$ 时，我们仍可以继续增加基学习器的数目以获得更好的模型性能。